



DETECCIÓN DE RETRASOS EN LA ENTREGA

Sistema de inteligencia logística -
OlistRisk

Elaborado por:

Luz Alizon Mamani Mena

Freddy Marquez Coronel

1. Resumen

El sistema Olist Risk Engine predice la probabilidad de que un pedido llegue tarde respecto a la fecha prometida al cliente, usando exclusivamente información disponible al momento de la compra. El modelo champion es una Regresión Logística tuneada (WOE Encoding), elegida por ser el único modelo evaluado sin sobreajuste entre los 4 algoritmos probados (Regresión Logística, Random Forest, LightGBM, XGBoost).

Este informe cubre seis dimensiones de responsabilidad: variables utilizadas y excluidas, sesgos identificados, riesgos del modelo, limitaciones declaradas, privacidad de datos, y gobernanza/monitoreo continuo.

Hallazgos críticos de este informe:

- Se detectó y documentó un bug real en el pipeline de producción: las categorías de producto se clasifican con un catálogo en inglés que no coincide con las categorías reales de Olist (en portugués), por lo que la variable `logistic_complexity` nunca varía en producción.
- El modelo presenta drift temporal real y medido (PSI hasta 0.40 en la variable más importante) entre el período de entrenamiento y julio 2018.
- Con el umbral por defecto (0.50), el ROI del sistema es negativo en el último mes evaluado, un resultado correcto y esperado dado el drift detectado, no un error de cálculo.

2. Variables utilizadas

El modelo final utiliza 50 variables agrupadas en 6 categorías, seleccionadas mediante un pipeline de 3 filtros (Missing rate, PSI, Correlación) sobre 67 variables candidatas construidas en el feature engineering.

2.1 Grupos de variables

Grupo	Cantidad	Ejemplos	Justificación de negocio
Temporales	15	<code>purchase_weekday</code> , <code>estimated_delivery_days</code> , <code>high_risk_day</code>	Capturan si el día/hora de compra y la promesa de entrega afectan el resultado
Geográficas	6	<code>region_risk_score</code> , <code>same_state</code> , <code>complex_route</code>	Capturan complejidad logística regional, no solo distancia
Producto	10	<code>volume_cm3</code> , <code>logistic_complexity</code> , <code>tiene_varios_vendedores</code>	Capturan complejidad física y operativa del pedido

Pago	8	freight_ratio, is_boleto, freight_per_kg	El método de pago puede introducir demoras de aprobación
Historial vendedor	3	seller_late_rate_hist (rolling, sin leakage)	El comportamiento pasado del vendedor predice el futuro
Score compuesto	3	risk_score, region_x_complexity	Combina señales múltiples en un índice interpretable

2.2 Ninguna variable usa datos personales identificables

Ningún nombre, correo electrónico, número de teléfono o dirección exacta del comprador o vendedor forma parte del modelo. La geolocalización se trabaja a nivel de estado (por ejemplo SP, RJ), nunca con coordenadas o direcciones específicas.

3. Variables excluidas y control de data leakage

3.1 Variables excluidas explícitamente

Variable / grupo excluido	Razón de exclusión
Geolocalización exacta (lat/long)	Se usó proxy por región/estado; coordenadas exactas no aportaban valor adicional verificado y aumentaban el riesgo de sobreajuste geográfico
Reviews del comprador	Data leakage: el review se genera después de la entrega, el modelo no puede conocerlo al momento de la predicción
order_delivered_customer_date y derivadas	Es la fecha real de entrega, usarla sería leakage directo del resultado que se quiere predecir
Nombre, email, teléfono	Sin valor predictivo declarado y con riesgo de privacidad innecesario

3.2 Control de leakage en el historial del vendedor

La variable seller_late_rate_hist, una de las dos o tres más importantes del modelo, se calculó con una ventana expanding (rolling), de forma que para el pedido N de un vendedor se usa únicamente el historial de los pedidos 1 a N-1. Vendedores sin historial reciben la media global como imputación (11.1% de tasa de retraso, verificada empíricamente en la muestra real del dataset).

4. Sesgos identificados

4.1 Sesgo geográfico por volumen de datos

Algunos estados presentan tasas de incumplimiento extremas calculadas sobre muestras muy pequeñas, lo que las hace estadísticamente poco confiables pero el modelo las trata con el mismo peso que estados con miles de pedidos:

Estado	Tasa de tardíos	Nº pedidos	Confiabilidad
CE (Ceará)	48.6%	177	Baja-media
AM (Amazonas)	18.8%	16	Muy baja — alta varianza
TO (Tocantins)	45.0%	40	Baja — alta varianza
RJ (Río de Janeiro)	36.4%	1,743	Alta — señal robusta
MG (Minas Gerais)	17.1%	1,646	Alta — señal robusta

El WOE Encoding no diferencia entre una tasa robusta (RJ, 1,743 pedidos) y una ruidosa (AM, 16 pedidos), ambas se codifican con el mismo procedimiento estadístico, lo que puede sobrepenalizar regiones con poca data histórica.

4.2 Bug de clasificación de categorías de producto (hallazgo crítico)

Este es un sesgo sistemático real del pipeline de entrenamiento, no del simulador ni de este informe: el modelo entrenado efectivamente nunca distinguió complejidad de producto en la práctica, aunque la variable forma parte del catálogo de 50 features finales. Se documenta aquí con total transparencia para su corrección en la versión de monografía del proyecto.

4.3 Sesgo de “vendedor nuevo”

Vendedores sin historial (`seller_total_orders_hist = 0`) reciben la tasa media global como imputación. Esto puede penalizar a vendedores nuevos legítimos que aún no tuvieron oportunidad de construir un historial, tratándolos como “riesgo promedio” cuando en realidad son un caso de incertidumbre, no de riesgo confirmado.

4.4 Sesgo temporal

El modelo se entrenó con datos de septiembre 2016 a marzo 2018, un período de fuerte crecimiento de Olist. Patrones de comportamiento de compradores, vendedores y logística actuales podrían diferir sustancialmente de ese período histórico.

5. Riesgos del modelo

5.1 Riesgo de falsos positivos en producción

Con el umbral por defecto (0.50) evaluado sobre julio 2018: el modelo emitió 3,145 falsas alarmas frente a solo 179 alertas correctas (precisión de aproximadamente 5.4%). Esto generó un costo de intervención estimado de R\$26,592 frente a un ahorro bruto de R\$5,638, resultando en un ROI negativo de aproximadamente -79%.

5.2 Riesgo de falsos negativos

Un pedido tardío no detectado significa que ningún mecanismo de intervención preventiva se activa, y el cliente experimenta el retraso sin ningún tipo de mitigación previa por parte de Olist.

5.3 Riesgo de uso indebido fuera del contexto previsto

Este modelo fue diseñado como herramienta interna de apoyo operativo, no como sistema de decisión automática ni como información expuesta al comprador final. Usarlo para negar servicio, penalizar vendedores automáticamente, o comunicar directamente la probabilidad de incumplimiento al comprador, excede el alcance validado de este proyecto.

6. Limitaciones declaradas

- El modelo se entrenó con datos hasta marzo 2018 y se validó hasta julio 2018. No incorpora ningún evento posterior a esa fecha.
- Agosto 2018 fue excluido completamente del dataset por censura de datos: pedidos sin fecha de entrega confirmada en el corte de extracción no pueden usarse para evaluar cumplimiento real.
- El AUC-ROC cae de 0.75 en Validación a 0.66 en Live (julio 2018), el modelo pierde poder discriminativo en el período más reciente disponible, señal de drift.
- Se identificó que la variable `logistic_complexity` no varía en la práctica por el bug de idioma descrito en la sección 4.2, su aporte real al modelo es menor al que su presencia en el catálogo de variables sugeriría.
- Los supuestos de costo usados para calcular ROI (R\$45 por reclamo evitado, R\$8 por intervención, 70% de tasa de éxito de intervención) son estimaciones razonadas para este proyecto académico, no cifras confirmadas por el equipo de operaciones real de Olist.
- El simulador de pedido interactivo aproxima variables que en producción real provienen de tablas de catálogo de productos (dimensiones, peso), en este MVP se solicitan como inputs directos del usuario.

7. Privacidad

El modelo opera exclusivamente sobre variables agregadas, categóricas de ubicación a nivel estado, y características transaccionales del pedido. No se procesa, almacena ni expone información de identificación personal directa (nombre, documento, dirección exacta, contacto).

Los identificadores de pedido y cliente presentes en las tablas fuente se usan únicamente para trazabilidad interna durante el desarrollo (joins entre tablas, verificación de duplicados) y se excluyen explícitamente de las variables que recibe el modelo entrenado.

8. Gobernanza y monitoreo continuo

8.1 Versionado

El modelo se registra con número de versión semántico (v3.0.0) y fecha de entrenamiento, trazable en el archivo `champion_resumen_v3.json`. Cada reentrenamiento debe incrementar la versión y conservar el historial de versiones anteriores.

8.2 Regla de decisión de reentrenamiento

Se implementó una regla cuantitativa y automatizable para decidir si el modelo necesita reentrenamiento, evaluada sobre el período más reciente disponible (proxy de producción):

SI $AUC < 0.65$ y $PSI > 0.25$ en más de 3 variables críticas -> REENTRENAR EN CUALQUIER OTRO CASO -> MODELO ESTABLE

Aplicada sobre julio 2018, esta regla señaló la necesidad de reentrenamiento, consistente con el drift documentado en la sección 5.1. Este resultado valida que el sistema de monitoreo cumple su función: detectar automáticamente cuándo el modelo deja de ser confiable en el contexto vigente.

8.3 Explicabilidad

Toda predicción puede descomponerse en sus factores: SHAP values (impacto real de cada variable sobre la predicción según su distribución) y coeficientes de la Regresión Logística (peso asignado por el modelo en su fórmula). Se documenta explícitamente que ambas vistas son válidas y responden preguntas distintas, para evitar que se interpreten como contradictorias.

8.4 Responsable humano

El modelo asiste la decisión operativa, no la reemplaza. Toda intervención final, renegociar un plazo, contactar a un vendedor, priorizar un despacho, la ejecuta una persona del equipo de operaciones. El sistema no está autorizado a tomar acciones automáticas sobre pedidos o vendedores.

8.5 Política de uso

- El sistema es de uso interno (operaciones, logística, atención a vendedores). No debe exponerse al comprador final.
- Ninguna decisión de penalización, suspensión o trato diferenciado hacia un vendedor debe tomarse exclusivamente en base al score del modelo, sin revisión humana.
- Los supuestos de costo de negocio deben revisarse y actualizarse junto con el equipo de operaciones real antes de cualquier despliegue más allá de este MVP académico.

9. Conclusión

Este informe documenta con transparencia tanto las fortalezas como las limitaciones reales del sistema Olist Risk Engine. Un sistema de inteligencia artificial responsable no es aquel que oculta sus fallas, sino aquel que las detecta, las mide y construye los mecanismos —como la regla de reentrenamiento implementada en la sección 8.2— para responder a ellas de forma sistemática.

El hallazgo del bug de idioma en la clasificación de categorías (sección 4.2) y el drift temporal medido con PSI (sección 5.1) no se presentan como fallas ocultas, sino como evidencia de que el proceso de auditoría y monitoreo del modelo funciona según lo previsto.